


IA Estratégica en Tres en Línea

Entrenamiento de agentes inteligentes para predecir jugadas óptimas mediante Random Forest, Gradient Boosting y Redes Neuronales



El Desafío: Más Allá de Clasificar

Objetivo Central

No solo clasificar partidas como ganadas o perdidas, sino dotar a la máquina de capacidad para tomar decisiones estratégicas óptimas.

Enfoque Innovador

Entrenar un agente que observe el estado del tablero y prediga la mejor jugada para ganar o asegurar empate.



Anatomía del Dataset

01

Estado del Tablero

9 columnas representan las casillas (0-8) con valores 'X', 'O' o '_' (vacía)

02

Turno del Jugador

Variable crucial que indica quién juega ('X' u 'O'). Misma configuración requiere respuestas diferentes según turno

03

Movimiento Óptimo

Variable objetivo: índice de casilla (0-8) que representa la mejor jugada matemática y estratégica

Problema técnico: **clasificación multiclase** con 10 entradas (tablero + turno) y 9 posibles salidas

Random Forest: Sabiduría de las Masas

Funcionamiento

Crea cientos de árboles de decisión simples. Cada árbol "vota" sobre la jugada óptima y se selecciona la mayoría.

Ventajas

- Estabilidad: promedia errores individuales
- Evita sobreajuste (memorización)
- Identifica casillas más importantes

Desventajas

- Pesado en memoria (almacena cientos de árboles)
- Predicción más lenta por conteo de votos



Aplicaciones: Diagnósticos médicos y detección de fraude bancario

Gradient Boosting: Corrección Secuencial

1

Árbol 1

Predicción general inicial

2

Árbol 2

Corrige errores del primero

3

Árbol 3

Refina errores del segundo

4

Árbol N

Optimización iterativa continua

Ventajas

Uno de los más precisos para datos tabulares. Se enfoca en casos difíciles, logrando exactitud superior.

Desventajas

Delicado de entrenar. Riesgo de sobreajuste. Difícil de paralelizar (secuencial).

Red Neuronal: Inspiración Cerebral

1

Capa de Entrada

Datos del tablero ingresan al sistema

2

Capas Ocultas

Neuronas aplican transformaciones ponderadas

3

Capa de Salida

Decisión final de jugada


4

Retropropagación

Ajuste de pesos para reducir error

Ventajas: Capacidad infinita para aproximar funciones complejas. Captura interacciones sutiles entre casillas.

Desventajas: Caja negra difícil de explicar. Requiere muchos datos y hardware especializado.



Metodología: Proceso KDD




Selección de Datos

Ingesta de 958 instancias desde repositorio remoto




Preprocesamiento

Limpieza de caracteres corruptos y validación de valores nulos



Transformación

Codificación numérica: X=1, O=-1, _=0. Estandarización para MLP



Particionamiento

80% entrenamiento, 20% prueba para validación



Minería de Datos

Configuración de hiperparámetros para cada modelo

Configuración de Modelos



Random Forest

200 estimadores (árboles) para maximizar reducción de varianza



Gradient Boosting

Tasa de aprendizaje 0.1, profundidad máxima 3 niveles por árbol



MLP

2 capas ocultas (128 y 64 neuronas), activación ReLU, optimizador Adam

Métricas de Validación

- **Reporte de Clasificación:** Precisión, Recall y F1-Score para cada jugada
- **Matriz de Confusión:** Visualización de predicciones vs. jugadas ideales


Random Forest

Gradient Boosting

MLP

≡≡≡ Reporte de Clasificación Gradient Boosting ≡≡≡				
	precision	recall	f1-score	support
0	0.95	0.99	0.97	147
1	0.98	0.96	0.97	100
2	0.99	0.99	0.99	130
3	1.00	0.98	0.99	138
4	0.99	0.99	0.99	142
5	1.00	0.96	0.98	67
6	0.96	1.00	0.98	107
7	1.00	0.97	0.98	63
8	0.98	0.99	0.99	106
accuracy			0.98	1000
macro avg	0.98	0.98	0.98	1000
weighted avg	0.98	0.98	0.98	1000


Matriz de Confusión - Gradient Boosting



≡≡≡ Reporte de Clasificación Random Forest ≡≡≡


	precision	recall	f1-score	support
0	0.94	0.98	0.96	147
1	0.95	0.98	0.97	100
2	0.98	0.96	0.97	130
3	0.96	0.98	0.97	138
4	1.00	0.98	0.99	142
5	0.97	0.91	0.94	67
6	0.97	0.98	0.98	107
7	0.98	0.94	0.96	63
8	0.96	0.96	0.96	106
accuracy			0.97	1000
macro avg	0.97	0.96	0.97	1000
weighted avg	0.97	0.97	0.97	1000

Matriz de Confusión - Random Forest



≡≡≡ Reporte de Clasificación MLP ≡≡≡					
	precision	recall	f1-score	support	
0	0.96	1.00	0.98	147	
1	1.00	1.00	1.00	100	
2	1.00	0.99	1.00	130	
3	0.99	0.99	0.99	138	
4	0.99	0.99	0.99	142	
5	0.98	0.96	0.97	67	
6	0.99	1.00	1.00	107	
7	1.00	0.97	0.98	63	
8	1.00	0.97	0.99	106	
accuracy			0.99	1000	
macro avg	0.99	0.99	0.99	1000	
weighted avg	0.99	0.99	0.99	1000	

Matriz de Confusión - Red Neuronal (MLP)



Resultados: MLP Triunfa

1 MLP

Destaca su capacidad para modelar relaciones no lineales complejas, capturar patrones espaciales implícitos (amenazas diagonales, combinaciones de ataque-defensa, dependencias contextuales). La codificación numérica centrada en cero favoreció el aprendizaje mediante retropropagación.

2 Random Forest

Rendimiento sólido y estable, pero su enfoque basado en reglas discretas limitó su capacidad para generalizar patrones estratégicos más sutiles.

3 Gradient Boosting

Alta precisión en escenarios específicos pero sensible a hiperparámetros y al tamaño reducido del dataset, afectando su generalización.